

Previsão de Fluxo de Tráfego Rodoviário com *Machine Learning*

Mestrado em Inteligência Artificial, Universidade do Minho

13/01/2026

Pedro Reis
PG59908

João Azevedo
PG61693

Guilherme Pinto
PG60225

Luís Silva
PG60390

1 . Introdução

Contextualização

Problema: Prever o fluxo de tráfego rodoviário na cidade do Porto, lidando com a natureza estocástica e não-linear da mobilidade urbana.

Cenário:

- **Fonte:** Dados históricos reais, em 2018 e 2019.
- **Desafio:** Transformar dados bruto em inteligência preditiva.

Projeto

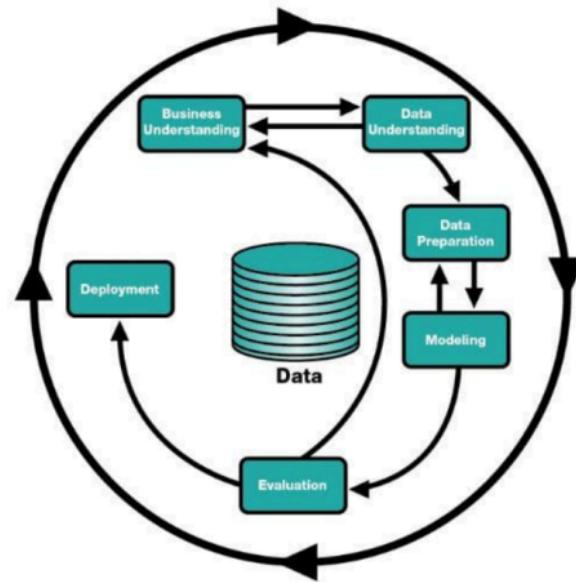
- Análise Exploratória;
- Engenharia de Atributos;
- Comparação de Modelos;
- Validação em Competição.

Metodologia

Adotou-se o processo iterativo CRISP-DM:

1. Compreensão do Negócio;
2. Compreensão dos Dados;
3. Preparação dos Dados;
4. Modelação;
5. Avaliação.

Iteração contínua entre a preparação dos dados e a modelação para otimização de performance.



2 . Compreensão do Negócio

Enquadramento do Problema

O **desafio** central é a previsão precisa do fluxo de tráfego num intervalo temporal específico, classificando a severidade do congestionamento (problema *multiclass*).

A **complexidade** do cenário trata-se de um fenómeno estocástico e não-linear, influenciado por:

- Padrões temporais;
- Condições meteorológicas;
- Comportamento humano imprevisível.

Valor e impacto social

A capacidade de perceber quais os fatores que influenciam os congestionamentos permite:

1. **Otimização de rotas:** Crucial para veículos de emergência.
2. **Sustentabilidade:** Redução de emissões poluentes.
3. **Qualidade de vida:** Gestão proativa do tráfego urbano e redução do tempo de viagem.

1. Extração de Conhecimento

Perceber como variáveis observadas definem matematicamente as diferentes classes de tráfego.

2. Excelência Preditiva

Maximizar a capacidade do modelo em distinguir corretamente entre categorias vizinhas usando os dados disponíveis.

3. Robustez e Generalização

Garantir que o modelo mantém a performance em cenários de tráfego atípicos.

4. Validação Competitiva

Prova de conceito através do *ranking* Kaggle: a capacidade de generalizar a classificação para dados nunca vistos.

3 . Compreensão dos Dados

Análise Univariada: Variável Alvo

Definição: Diferença entre a velocidade de fluxo livre e a velocidade real.

Ausência do “None”: A categoria “None” foi interpretada como `NaN` durante o processo de ingestão.

Análise de Distribuição:

- Desequilíbrio severo:** A classe “None” domina com 32.3%.
- Escassez de casos críticos:** A classe “Very_High” representa apenas 7.1%.

Consequência: O modelo terá tendência natural a subestimar o trânsito grave.

Classe	Frequência
NaN	32.3%
Low	20.8%
Medium	24.2%
High	15.6%
Very_High	7.1%

Dinâmica Temporal (`record_date`)

- **Formato Bruto:** Timestamp (MM/DD/YYYY HH:MM).
- **Desafio:** Não é interpretável diretamente por algoritmos.
- **Potencial:** Esconde padrões cíclicos cruciais.

ID	record_date
0	8/29/2019 7:00
1	8/10/2018 14:00
2	9/1/2019 16:00
3	2/26/2019 11:00
4	6/6/2019 12:00

Problemas críticos de qualidade Identificaram-se falhas graves nas variáveis `AVERAGE_RAIN` e `AVERAGE_CLOUDINESS` que exigem intervenção imediata.

`AVERAGE_RAIN`

1. Inconsistência de nulos

Valores em falta representados de múltiplas formas: `NULL` e strings vazias.

2. Ausência de “zero”

Não existe uma categoria explícita para “ausência de chuva”, obrigando a deduções lógicas.

3. Redundância

Categorias sobrepostas que dificultam a distinção da intensidade.

`AVERAGE_CLOUDINESS`

1. Lacunas de Informação

Ao contrário da chuva, os valores em falta representam uma perda real de dados e não apenas “céu limpo”.

2. Ruído Categórico

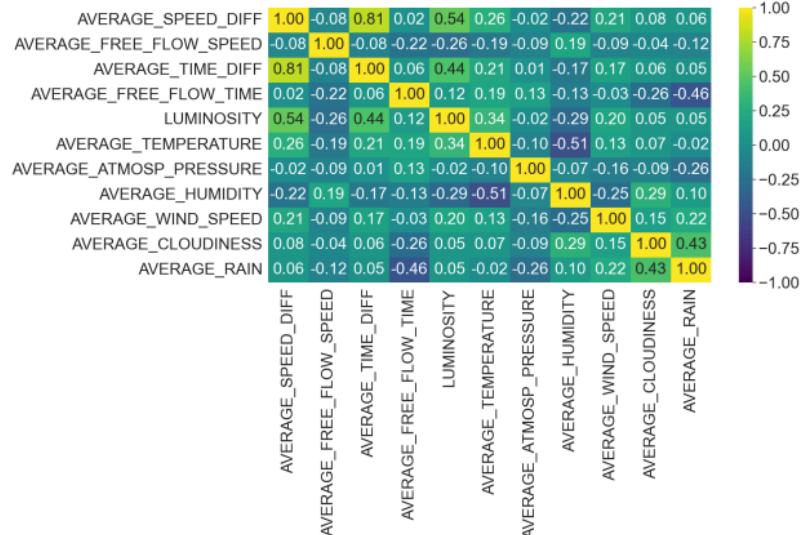
Existência de termos sinónimos e distinções demasiado subtis que diluem a informação.

- **AVERAGE_SPEED_DIFF**

- Correlação de **0.81** com **AVERAGE_TIME_DIFF**.
- Correlação de **0.54** com **LUMINOSITY**.

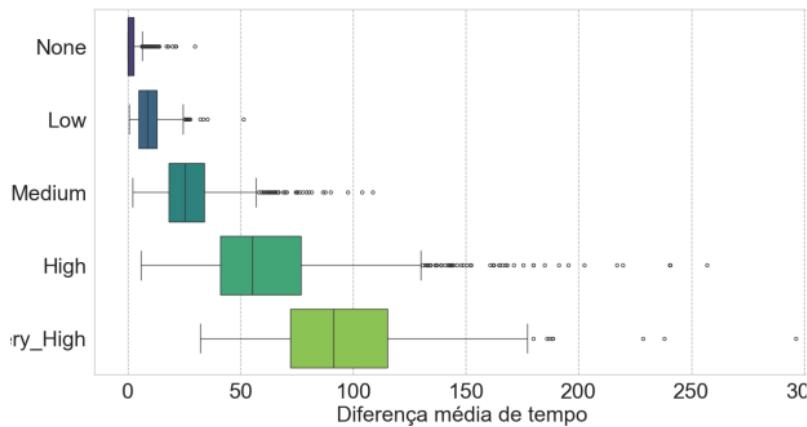
- **Multicolinearidade**

- Correlação inversa de **-0.51** entre **TEMPERATURE** e **HUMIDITY**.
- Correlação de **0.43** entre **AVERAGE_CLOUDINESS** e **AVERAGE_RAIN**.



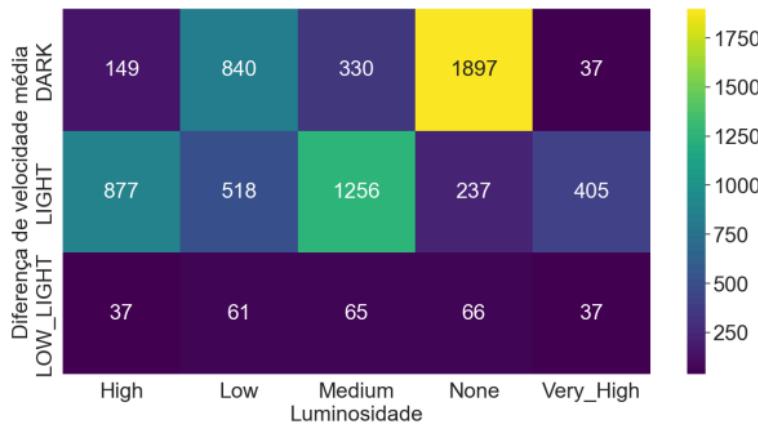
AVERAGE_TIME_DIFF

Observa-se uma progressão estritamente crescente: quanto maior o atraso, mais grave a classe.



LUMINOSITY

- “DARK”: Predominância de “None”, por ser durante a noite.
- “LIGHT”: Concentração de transito.



4 . Preparação dos Dados

A análise exploratória identificou erros de ingestão e definições de negócio em falta que exigiram intervenção manual antes de qualquer imputação.

Correção de *Parsing*, **AVERAGE_SPEED_DIFF**

Problema: A categoria “None” foi erradamente interpretada como NaN.

Impacto: A exclusão destes registo eliminaria 32.3% dos dados, enviesando o modelo para cenários de tráfego intenso.

Solução: Substituir os *missing values* por a categoria “None”.

Inferência de Negócio , **AVERAGE_RAIN**

Problema: Elevada taxa de NULL e inexistência da categoria “Sem Chuva”.

Análise: A inspeção dos dados brutos revelou que NULL correspondia a ausência de registo pluviométrico.

Solução: Conversão de NULL → “Sem Chuva”.

Para lidar com a redundância semântica e o desequilíbrio de classes nas variáveis meteorológicas, aplicou-se redução de dimensionalidade.

Variável	Problema Identificado	Transformação
AVERAGE_RAIN	13 categorias redundantes e ruído.	Binária: Agrupamento em “Sem Chuva” e “Com Chuva” para focar no impacto macroscópico.
AVERAGE_CLOUDINESS	9 categorias com distinções subtis e classes raras.	Ordinal: Redução para “Céu Limpo”, “Parcialmente Nublado” e “Nublado”.

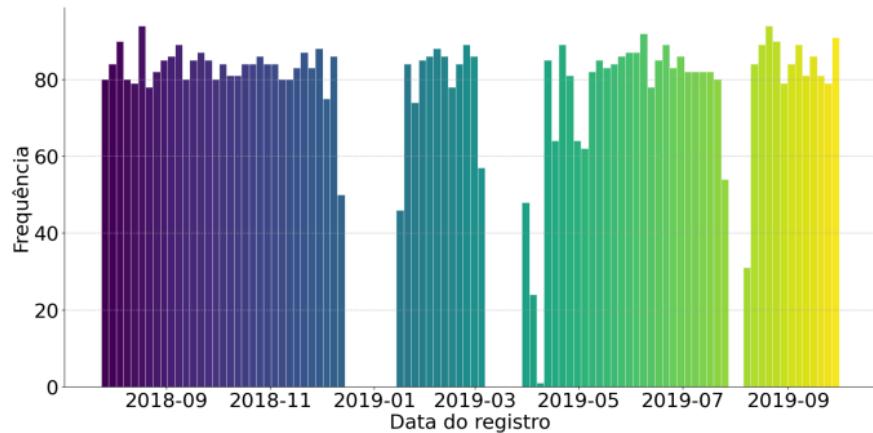
Para preencher lacunas reais de informação, realizou-se um estudo comparativo de métodos.

Métodos Rejeitados:

- **Machine Learning:** Introduziu um viés considerável, distorcendo a distribuição estatística original.
- **Moda:** Demasiado estática para séries temporais.

Método Selecionado: *Forward Fill*

- **Lógica:** Propaga a última observação válida.
- **Justificação:** Respeita a inércia temporal dos fenómenos meteorológicos.
- **Validação:** Apesar das descontinuidades temporais observadas na figura, assume-se a persistência do estado como a aproximação mais conservadora.



Remoção de variáveis

Atributos sem variância (informação discriminativa) foram eliminados:

- **city_name**
- **AVERAGE_PRECIPITATION**

Label Encoding

Dada a natureza ordinal das variáveis categóricas, optou-se por *Label Encoding* em vez de *One-Hot*.

- **AVERAGE_SPEED_DIFF**
- **LUMINOSITY**
- **AVERAGE_RAIN**
- **AVERAGE_CLOUDINESS**

Problema: A representação linear da hora (0-23) cria uma descontinuidade artificial (23h e 00h parecem distantes).

Solução: Transformação trigonométrica com a projeção da hora num círculo unitário para preservar a proximidade temporal matemática.

$$\text{'hour_sin'} = \sin\left(\frac{2\pi \cdot \text{'hour'}}{24}\right)$$

$$\text{'hour_cos'} = \cos\left(\frac{2\pi \cdot \text{'hour'}}{24}\right)$$

Outras Extrações: Decomposição de `record_date` em: Dia da semana, Semana, Mês, Dia do ano e Ano.



Normalização e tratamento de *outliers*

- **Min-Max Scaling:** Todas as variáveis numéricas escaladas para [0, 1] para ajudar na convergência.
- **Outliers:** Em tráfego, os extremos não são ruído, são os eventos de interesse (acidentes, congestionamento).

Balanceamento dos dados de treino

Combinação de duas técnicas robustas:

1. **Stratified K-Fold:** Mantém a proporção das classes na validação.
2. **Oversampling com SMOTE:** Geração de dados sintéticos para as classes minoritárias.

Comparativo de três abordagens para reduzir a dimensionalidade e evitar *overfitting*:

Método	Análise	Decisão
PCA <i>(Principal Component Analysis)</i>	Reduz a dimensionalidade eficazmente, mas sacrifica a interpretabilidade semântica das variáveis (perda de significado físico).	Rejeitado
PSO <i>(Particle Swarm Optimization)</i>	Inviável devido à explosão combinatória do tempo de execução quando acoplado à otimização de hiperparâmetros.	Rejeitado
Eliminação Iterativa <i>(Manual Backward Elimination)</i>	Baseada na Feature Importance . Permitiu reduzir a complexidade e validar os preditores dominantes face à realidade do negócio.	Selecionado

5 . Modelação

A abordagem seguiu uma evolução de complexidade incremental para equilibrar o enviesamento (*bias*) e a variância.

1. Baselines

Estabelecer o chão de performance com modelos interpretáveis.

Decision Tree, Logistic Regression

2. Redução de Variância

Capturar não-linearidade e reduzir ruído.

SVM, Random Forest, Boosting

3. Meta-Learning

Generalização máxima via arquiteturas complexas.

Deep Learning, Stacking

Nota: Otimização transversal via *Grid Search* em todos os modelos (em exceto o *Deep Learning*).

Modelos: Referência

O ponto de partida para validar a complexidade futura.

Decision Tree

Segmentação não-linear via regras hierárquicas.

criterion	Gini
max_depth	7
min_samples_split	3
min_samples_leaf	1

accuracy: 0.77

Logistic Regression

Baseline linear paramétrica com regularização L1 (*sparsity*).

penalty	L1 (lasso)
solver	saga
C	1.0
max_iter	2000

accuracy: 0.77

Aumentar a complexidade para capturar fronteiras não-lineares e melhorar a generalização.

Support Vector Machine

Maximização de margem via *Kernel Trick*.

kernel	poly
C	10
gamma	scale

accuracy: 0.79

Random Forest

Ensemble (Bagging) para robustez.

n_estimators	120
max_depth	18
criterion	entropy
min_samples_split	3
min_samples_leaf	1
bootstrap	true

accuracy: 0.81

Estratégia sequencial: cada novo modelo foca-se em corrigir os erros residuais do anterior.

Gradient Boosting

Otimização direta da função de perda (*loss*).

n_estimators	150
--------------	-----

accuracy: 0.81

XGBoost

Versão otimizada com regularização na função objetivo.

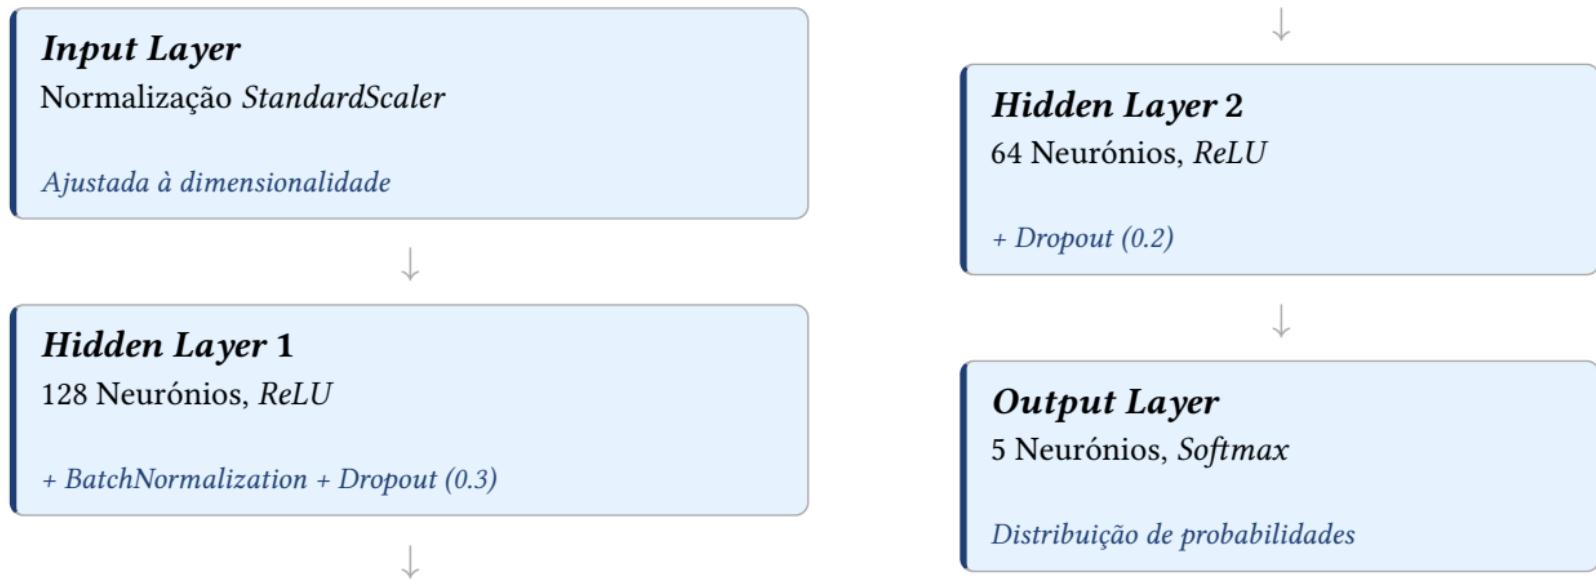
max_depth	6
-----------	---

n_estimators	120
--------------	-----

colsample_bytree	0.8
------------------	-----

accuracy: 0.81

Rede *Feedforward* (MLP) desenhada para capturar relações não-lineares de alta ordem.



Configuração

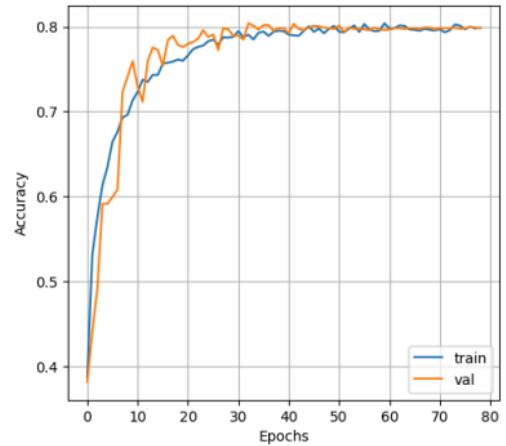
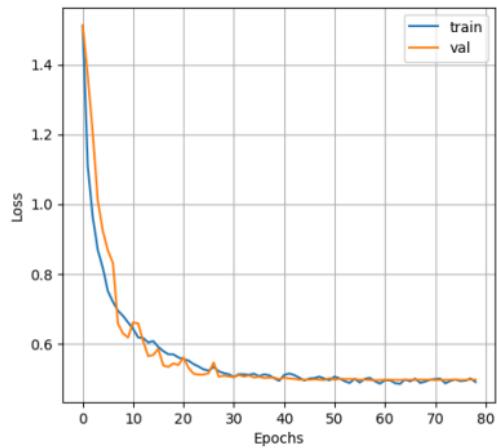
Otimizador: Adam ($lr = 0.001$)

Loss Fn Categorical Crossentropy

Callbacks

- EarlyStopping (P: 20)
- ReduceLROnPlateau

accuracy: 0.80



Motivação: Mitigar o viés do desequilíbrio de classes, forçando o sistema a especializar-se em categorias específicas em vez de otimizar uma função de perda global.

Estratégia One-vs-Rest: Decomposição do problema *multiclass* em 5 sub-problemas binários.

- **Inovação:** Aplicação de SMOTE. O *oversampling* ocorre apenas dentro do problema binário, evitando ruído nas fronteiras globais.
- **Decisão:** Competição direta, ganha o agente que apresentar maior grau de confiança.

accuracy: 0.80

Mixture of Experts (MoE): Implementação de computação condicional dinâmica.

- **Experts:** Classificadores treinados em diferentes perspectivas dos dados.
- **Gating Network:** Um “Supervisor” que avalia o contexto e decide qual o perito mais competente para aquele cenário.
- **Decisão:** Soma ponderada dinâmica (não é uma votação democrática estática).

accuracy: 0.79

Conceito: Arquitetura onde um “meta-modelo” aprende a corrigir os erros dos modelos base, ponderando a fiabilidade de cada um em diferentes cenários.

Arquitetura Heterogénea

Nível 1 (*Base Learners*):

- Random Forest
- XGBoost
- Gradient Boosting
- SVM (Poly)
- Logistic Regression



Nível 2 (*Meta-Learner*):

- Logistic Regression

Integração de Fronteiras de Decisão: Ao contrário dos *ensembles* homogéneos, o *Stacking* combina visões geométricas distintas:

- **Linearidade** (*Logistic Regression*);
- **Hiperplanos Multidimensionais** (*SVM*);
- **Cortes Ortogonais** (Modelos baseados em árvores).

Conclusão: O modelo capturou a complexidade onde algoritmos individuais falharam.

accuracy: 0.82

6 . Avaliação

Destaques

- **Stacking:** Melhor desempenho global de 82%, beneficiando da heterogeneidade dos modelos base.
- **Ensembles (Tree-based):** Convergência num teto de 81% (RF, XGBoost, GBM).
- **Baselines:** Estagnaram nos 77%, limitados pela linearidade ou simplicidade.

Modelo	Accuracy	F1-Score
<i>Stacking</i>	0.82	0.82
<i>XGBoost</i>	0.81	0.81
<i>Random Forest</i>	0.81	0.81
<i>Gradient Boosting</i>	0.81	0.81
ANN	0.80	0.80
<i>One-vs-Rest</i>	0.80	0.80
SVM	0.79	0.79
<i>Logistic Regression</i>	0.77	0.77
<i>Decision Tree</i>	0.77	0.78

A consistência entre a validação local e o *ranking* na competição Kaggle confirma a ausência de *overfitting* significativo.

Métricas de Validação:

Estimativa Local:	0.820
Public Score (30%):	0.835
Private Score (70%):	0.813

Análise de Erros:

- O modelo demonstra um comportamento **conservador**.
- A maioria dos erros ocorre entre **classes adjacentes**, o que é menos penalizador num contexto real de tráfego.

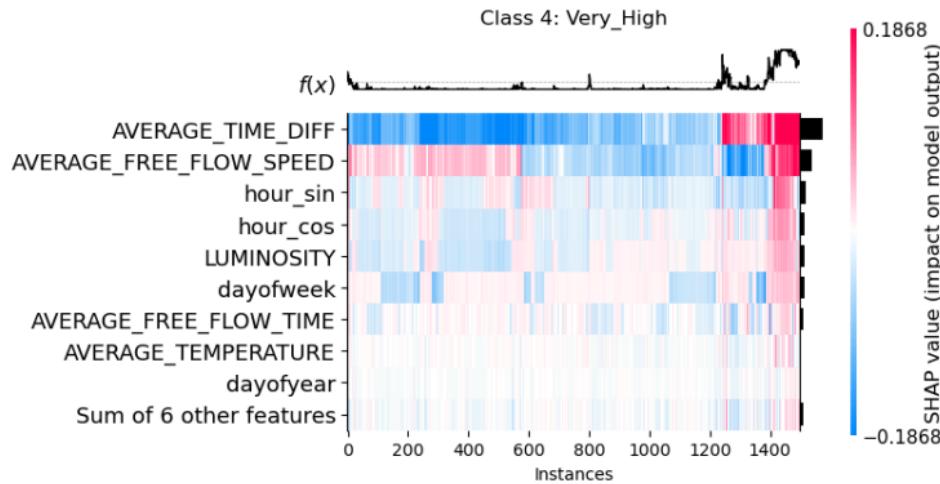
Apesar da complexidade, a análise SHAP revela que o modelo “aprendeu” os pontos chave do problema.

1. Dominância Causal

- **AVERAGE_TIME_DIFF** é o preditor transversalmente dominante. O modelo entende que o atraso é a definição direta de congestionamento.

2. Modulação Contextual

- Nas classes intermédias, o modelo usa a **LUMINOSITY** e a **hour** para refinar a probabilidade.



7 . Conclusão